

דוח סיכום: תהליך בנייה של סט נתוני סרטים

מגישה: נטע אור שאול

החלטות מרכזיות בבניית סט הנתונים

במסגרת הפרויקט, סט הנתונים נבנה תוך התמקדות בסרטים המתחילים באותיות U ו-V. תהליך הבנייה כלל מספר שלבים:

- סינון ראשוני:** הנתונים סוננו על פי קריטריונים של סרטים בלבד המתחילים באותיות U ו-V. שנת יציאה (סרטים שיצאו עד שנת 2024), סרטים באורך 60-300 דקות כפי שהוגדר בהנחיות העבודה.
- איסוף נתונים מ-Wikipedia:** כדי להשיג את המידע, השתמשתי בטכניקת Scraping שלמדנו בכיתה. בניתי קוד שמבצע התאמה אוטומטית של כתובת ה URL-לפי שם הסרט והשנה, ובמקרים שהכתובת לא נמצאה, נעזרתי ב-API של ויקיפדיה כדי לאתר את הדף המדויק. מהדפים שאותרו חולצו השפה, המדינה, התקציב והעלילה, תוך שימוש ב-Regex לניקוי הנתונים. ודיוק
- שיפור איכות וניקוי נתונים:** אחרי סבב האיסוף הראשון, שמתי לב שהיו סרטים שבהם נשלף רק תקציר העלילה בלי שום נתון אחר. הבנתי שזה קרה כי מנוע החיפוש היה רחב מדי והביא מידע מדפים דומים בוויקיפדיה שלא בהכרח היו דף הסרט המדויק כמו שקרה לדוגמה עם הסרט "Volcano" משנת 1926 שבו הקוד הגיע לדף כללי על תופעת טבע. לכן, החלטתי למחוק את המידע שאספתי מהשורות שבהן רק שדה התקציר היה מלא. ההחלטה הזו נבעה מהרצון להעדיף מידע אמין ומדויק על פני מאגר נתונים גדול ולא מבוסס, ובעקבות זאת ביצעתי סבב איסוף נוסף.
- סבב איסוף שני ומשלים מ-Wikipedia:** בעקבות הניקוי הזה נשארו לי חורים בטבלה והבנתי שיכול להיות עוד חוסרים בטבלה לכן החלטתי לבצע חיפוש נוסף בוויקיפדיה. הפעם שיפרתי את הקוד כך שיחפש בצורה יותר יסודית וינסה חיפוש שונה של שמות, כדי להצליח למצוא את הסרטים שפספסתי קודם ולהשלים כמה שיותר מידע.
- סבב העשרה נוסף (API):** על מנת להשלים נתונים חסרים נוספים על התקציר, בוצעו קריאות ל-API של OMDb. בגלל הגבלת ה-API ל-1,000 קריאות ביום, החלטתי על לוגיקה של תיעדוף הקריאות. קודם כל הושלם מידע עבור סרטים שבהם היה חסר תקציר בלבד, לאחר מכן סרטים עם חוסר בתקציר וחוסר נוסף אחר, ולבסוף סרטים עם חוסר בתקציב ובנוסף עוד שני חוסרים. דרך פעולה זו נועדה למקסם את העשרת בסיס הנתונים תחת מגבלת ה-API של OMDb.
- התאמת טיפוס נתונים וסדר עמודות:** התאמתי את הנתונים בטבלה שיהיו באותם סוגים שהתבקשנו בהנחיות העבודה. כחלק משלב התאמת הנתונים עדכנתי את הנתונים על ההכנסות והתקציב שאספתי אותם מוויקיפדיה כמו שהם, שיהיו ביחידות של מיליוני דולר (כמו שהתבקשנו), פעולה זאת כללה איסוף ממוקד מתוך הטבלה שלי של כל המטבעות הייחודיים הקיימים בטבלת הנתונים ולאחר מכן יצירת פונקציה שתבצע המרה של המטבע הזר למיליוני דולרים, בנוסף אם היה טווח חושב עבורו הממוצע וההמרה ליחידות במיליוני דולרים כמבוקש.
- בחירת הסט הסופי:** למרות שעבוד הנתונים המלא התבצע על מאגר של 11,121 סרטים, בסיס הנתונים המוגש כולל 5,000 סרטים. בחירת הסרטים נעשתה על פי דירוג איכות: קודם כל נבחרו הסרטים ללא ערכים חסרים כלל, ולאחר מכן סרטים עם ערך חסר אחד, וכן הלאה, עד להגעה ל-5000 סרטים כמבוקש בפרויקט.

תיאור שדות הנתונים

פירוט השדות הקיימים בסט הנתונים הסופי, סוג הנתון, מקורו וערכים חסרים:

שם השדה	Type	מקור הנתון	תיאור
tconst	String	IMDb	מזהה ייחודי של הסרט
primaryTitle	String	IMDb	השם המרכזי של הסרט
startYear	Int	IMDb	שנת יציאת הסרט
runtimeMinutes	Int	IMDb	משך הסרט בדקות
genres	List of strings	IMDb	ז'אנרים של הסרט
averageRating		IMDb	דירוג ממוצע של גולשים
numVotes		IMDb	מספר המצביעים
lead_actors_ids	List of strings	IMDb	מזהי 5 השחקנים הראשיים
Language	String	Wikipedia	השפה הראשית בסרט
Country	String	Wikipedia	מדינת מקור
budget	Float	Wikipedia	תקציב הסרט במיליוני דולרים
BoxOffice	Float	Wikipedia	הכנסות הסרט במיליוני דולרים
plot	String	Wikipedia / OMDb	תקציר הסרט

ערכים חסרים

בטבלה המקורית (הכוללת 11121 רשומות):

מספר הערכים החסרים הכולל עמד על **54,853** המהווים **37.94%** מהדאטה.
מצורפת טבלה אשר מראה את כמות ואחוז הערכים החסרים עבור כל שדה בטבלה המקורית, ואת אחוז הערכים החסרים שחילצנו בכולל מוויקפדיה ומ-OMDB

```

--- DETAILED PER-COLUMN COMPLETENESS (Cleaned) ---

```

Column Name	Empty Cells (Null)	Full Cells (Valid)	Null Percentage (%)
budget	10542	579	94.79%
BoxOffice	10372	749	93.26%
plot	8302	2819	74.65%
Country	8286	2835	74.51%
Language	8198	2923	73.72%
numVotes	3314	7807	29.80%
averageRating	3314	7807	29.80%
lead_actors_ids	1856	9265	16.69%
genres	669	10452	6.02%
tconst	0	11121	0.00%
primaryTitle	0	11121	0.00%
startYear	0	11121	0.00%
runtimeMinutes	0	11121	0.00%

```

=====
--- FINAL DATASET AUDIT SUMMARY (Cleaned) ---

```

Metric	Extraction (5 Cols)	Overall (13 Cols)
Total Cells	55,605	144,573
Empty (Null)	45,700	54,853
Full (Valid)	9,905	89,720
Null %	82.19%	37.94%
Full %	17.81%	62.06%

```

=====

```

בסט הנתונים הסופי (5,000 סרטים):

בטבלה המצומצמת המוגשת בפרויקט זה, מספר הערכים החסרים הוא **16,018** המהווים **24.64%** מכלל התאים בטבלה.
מצורפת טבלה אשר מראה את כמות ואחוז הערכים החסרים עבור כל שדה בטבלה המוגשת, ואת אחוז הערכים החסרים שחילצנו בכולל מוויקפדיה ומ-OMDB

```

--- DETAILED PER-COLUMN COMPLETENESS (FINAL 5000 SUBSET) ---

```

Column Name	Empty Cells (Null)	Full Cells (Valid)	Null Percentage (%)
budget	4423	577	88.46%
BoxOffice	4253	747	85.06%
Country	2247	2753	44.94%
plot	2217	2783	44.34%
Language	2170	2830	43.40%
numVotes	244	4756	4.88%
averageRating	244	4756	4.88%
lead_actors_ids	154	4846	3.08%
genres	66	4934	1.32%
tconst	0	5000	0.00%
primaryTitle	0	5000	0.00%
startYear	0	5000	0.00%
runtimeMinutes	0	5000	0.00%

```

=====
--- FINAL 5000 DATASET AUDIT SUMMARY ---

```

Metric	Extraction (5 Cols)	Overall (13 Cols)
Total Cells	25,000	65,000
Empty (Null)	15,310	16,018
Full (Valid)	9,690	48,982
Null %	61.24%	24.64%
Full %	38.76%	75.36%

```

=====

```